

Redes Neuronales Recurrentes con LSTM aplicado al Mantenimiento Predictivo Caso: Degradación de motores de turboventiladores

Martínez Alegria, Albert

Resumen — Nos encontramos a inicios de la cuarta revolución industrial o Industria 4.0. por lo que los sistemas inteligentes e inteligencia artificial esta en planes de diferentes requerimientos a nivel industrial. Es por ello que el mantenimiento predictivo (PdM) es uno de los tópicos que tiene muchos avances de Machine Learning en la actualidad, ya que el poder saber cuándo fallará una máquina en la línea de producción se traduce en un significativo ahorro económico, ya que no se gasta de más en traer repuestos de emergencia, y tampoco se para de manera imprevista la línea de producción, lo que es sumamente atractivo para cualquier empresa. Este documento presenta la aplicación de redes neuronales recurrentes (RNN) con Memoria de Largo a Corto Plazo (LSTM), para la predicción de falencias en la degradación de motores de turboventiladores, el mismo se realiza una clasificación binaria para poder identificar que motores llegarán a fallar antes de los 50 ciclos, y posteriormente, mediante la regresión se podrá saber la cantidad de ciclos restantes antes de su falla. El mismo puede ser aplicado para múltiples tareas de mantenimiento predictivo, pero al tratarse de motores, es ideal el utilizarlo para maquinaria rotativa.

Palabras clave — Machine Learning, Predictive Maintenance, LSTM, Long Short Term Memory, Mantenimiento Predictivo, Redes Neuronales Recurrentes, RNN, Industria 4.0.

Línea de investigación — Ciencias de la Computación.

I. INTRODUCCIÓN

Tras el crecimiento industrial en el ámbito boliviano, múltiples empresas comenzaron a invertir grandes sumas de dinero en maquinaria de alta o media potencia, teniendo un crecimiento del 2.6% con respecto a enero del anterior año en la industria manufacturera [1]. A fin de abarcar una demanda cada vez más creciente en un mercado altamente competente. Si bien la inversión se traduce en alza de la productividad y eficiencia en los procesos industriales, también implica la necesidad de procedimientos específicos a fin de mantener la correcta operación de esta maquinaria.

Uno de los problemas más temidos, en cuanto a maquinaria pesada se refiere, son las paradas de emergencia que generan gastos considerables, invertidos para la reparación de la máquina y a su vez, las ganancias perdidas por producción. Las paradas, son el producto de múltiples falencias, que, a lo largo de su vida operacional, pueden traducirse en reducir la eficiencia energética, la calidad de producción y en acortar la vida útil de la maquinaria [2]–[5].

Existen muchos métodos para detectar y evitar este tipo de problemas, desde el planeado de paradas para el mantenimiento, hasta el monitoreo continuo computarizado, que pueden advertir un futuro fallo, a este conjunto de métodos se les conoce como procesos de Mantenimiento Preventivo y Predictivo (PPM)¹. Este paradigma de mantenimiento comprende dos procesos, uno de mantenimiento preventivo y el otro predictivo, ambos con la finalidad de optimizar el trabajo de la maquinaria. Los efectos de estos procesos tienen como objeto, reducir los costos de mantenimiento y prolongar el tiempo de vida de la maquinaria, evitando así la aplicación del Mantenimiento Reactivo, que como su nombre lo indica, consiste en la reparación del equipo tras una falla de magnitud considerable, dejando inutilizable a la máquina [2][3].

Actualmente, a puertas de la Industria 4.0. el análisis de datos comienza a tener mayor relevancia, debido al aumento considerable en la capacidad computacional de las computadoras. Debido a ello, el sector industrial es uno de los que ha obtenido el mayor beneficio de este desarrollo, ya que la gran capacidad computacional ha permitido analizar y estudiar sistemas de monitoreo casi en tiempo real [6],[7],[8].

Generalmente, todos estos sistemas trabajan tras el monitoreo de datos proporcionados por los diferentes sensores en el sistema industrial, los cuales mandan una alarma cuando ocurre una falla o cuando algo no trabaja de manera correcta. El problema en este tipo de sistemas es que la falla se detecta sobre la marcha, y no se la previene [9].

En las *Smart Industries*², el Mantenimiento Predictivo (PdM)³ es una de las técnicas más usadas, debido a que evalúa la condición actual de diferentes equipos, con el fin de alertar sobre un posible fallo en el futuro. Lo que da tiempo al equipo

¹ Preventive & Predictive Maintenance (PPM, por sus siglas en inglés). - Programas para prevenir o predecir alguna futura falla en maquinaria.

² Industrias Inteligentes. - Se refiere a la transformación digital de los sectores productivos tradicionales por medio de la incorporación de TIC y

análisis y procesamiento de datos, volviéndolos adaptables y eficientes en el uso de recursos, así como altamente integrados entre sí.

³ Predictive Maintenance (PdM, por sus siglas en inglés). - Mantenimiento Predictivo.

de mantenimiento, el poder programar la reparación con días de antelación [10].

II. ANTECEDENTES

Durante muchas décadas, el mantenimiento de maquinaria ha desempeñado un papel vital en la industria debido a los enormes efectos económicos que las averías o fallas tienen en una empresa. Donde, se optimizan los tiempos de parada tanto en producción, como en mantenimiento correcto, al planificar la parada de mantenimiento basado en la condición de la maquinaria, véase la figura 1. Hoy en día, el mantenimiento sigue siendo un elemento vital de cualquier industria, existen cuatro modelos de mantenimiento que se pueden seguir [4],[11],[12]:

A. Mantenimiento Correctivo No Planificado

Es el tipo de mantenimiento que se realiza cuando ocurre una falla imprevista, por lo que es necesario reparar el equipo antes de que pueda seguir siendo usada. Por lo que, el mantenimiento correctivo no planificado, se centra en corregir las fallas lo más rápido posible para evitar daños materiales y humanos, con el objetivo de reducir las pérdidas económicas [11].

B. Mantenimiento Correctivo Planificado

El objetivo de este tipo de mantenimiento es anticipar posibles fallas o daños en el equipo que puedan ocurrir en cualquier momento. Esta se basa en la experiencia previa, como en la gestión de mantenimiento del personal de planta, donde se establecen períodos de mantenimiento para las diferentes partes del equipo, y, de esta manera, identificar partes desgastadas o futuras averías [3]. Por lo tanto, este tipo de mantenimiento se realiza con una revisión general, la cual diagnostica el estado actual de la maquinaria. El tiempo dedicado para esta revisión generalmente es programado de antemano para que se puedan aprovechar las horas de inactividad en paradas de mantenimiento o poca actividad en la línea de producción [11].




Fig. 1. Comparativa económica entre el Mantenimiento Preventivo y Predictivo.

C. Mantenimiento Predictivo

Se lo considera como un complemento del mantenimiento correctivo y preventivo. En este tipo de mantenimiento, se monitorean y analizan una serie de parámetros, los cuales son

generados por diferentes tipos de sensores, para determinar posibles anomalías [3]. En esencia, el proceso consiste en generar estimaciones o suposiciones sobre el estado de un componente en particular. Cuando se predicen procesos bien definidos, es posible generar un modelo matemático confiable que represente fielmente la realidad [12]. Sin embargo, otros tipos de procesos requieren técnicas experimentales, como algoritmos de clasificación [13] o redes neuronales artificiales (ANN⁴) [14], [15], [16], [17]. Este enfoque intenta extraer información y modelar el sistema sobre la base de datos históricos [3].

D. Mantenimiento Proactivo

Es una estrategia utilizada para mantener la estabilidad y el rendimiento de la maquinaria, su vida útil se prolonga al evitar errores y averías [3]. Hay dos tipos de reparación [18]:

- *Mantenimiento Perfecto*: Este tipo de mantenimiento ocurre cuando una máquina vuelve a su estado ideal, siendo por lo general altamente caro.

- *Mantenimiento Imperfecto*: Por otra parte, con este mantenimiento hay una pérdida considerable de calidad, pero el costo de reparación es reducido.

Otro punto a tener en cuenta en este último tipo de mantenimiento; es el rendimiento de la máquina. Ya que, debido a su deterioro natural, con el tiempo debería recibir revisiones periódicas a lo largo de su vida útil. Por lo tanto, se puede llevar a cabo un mantenimiento periódico. Donde el rendimiento de la máquina se evalúa periódicamente, a pesar de su rendimiento correcto [18]. La última solución no llega a ser óptima cuando el período de revisión es corto y el funcionamiento de la máquina es óptimo. De manera paralela, se puede controlar el estado de la maquinaria y evaluar sus parámetros. Un modelo que combina estas dos opciones se presenta en el trabajo de Dengji Zhou et al. en [19], donde la pérdida de rendimiento del equipo se predice en función de la tasa de falla y la degradación del rendimiento.

E. Redes Neuronales

Una de las técnicas más comunes para tratar este tipo de problema, son los modelos de redes neuronales. Las redes neuronales son un modelo simplificado que emula la forma en que el cerebro humano procesa la información [20]. Consisten en una gran cantidad de unidades de procesamiento interconectadas que trabajan simultáneamente para realizar el procesamiento de información. Existen diferentes modelos de redes neuronales que agrupan las neuronas de manera diferente.

F. Redes Neuronales Recurrentes

Las Redes Neuronales Recurrentes (RNN⁵), son un tipo de red neuronal artificial, cuya arquitectura incorpora memoria. El implementar memoria es posible, debido a que algunas neuronas reciben como entrada la salida de otra, de las capas anteriores. Por lo que es el mejor modelo para la regresión, debido a que toma en cuenta valores pasados [21]. Existen

⁴ Artificial Neural Networks. - Redes Neuronales Artificiales

⁵ Recurrent Neural Network. - Redes Neuronales Recurrentes

varios tipos de RNN, entre ellos, las redes de memoria a corto y largo plazo (LSTM⁶) [21].

III. MATERIALES Y MÉTODOS

A. Colab

También conocido como Colaboratory, es un servicio gratuito de Google, el cual proporciona una interfaz Jupyter Notebook con acceso al hardware de Google. Las blocs de notas o notebooks se ejecutan en máquinas virtuales (VM⁷) basadas en Linux, las cuales son proporcionadas y mantenidas por Google, donde el cálculo computacional se puede realizar con unidades de procesamiento central (CPU⁸) o también puede ser acelerado a través de unidades especializadas de procesamiento gráfico (GPU⁹) y unidades de procesamiento de tensorial (TPU¹⁰). El hardware disponible para cada VM varía según cada sesión, pero generalmente incluye una GPU NVIDIA (K80, T4 o P100), de 8 a 12 GB de RAM y 50 a 70 GB de espacio libre en el disco duro para manejar. Cabe recalcar que los notebooks de Colab no están diseñados para un uso de larga duración, es por ello que se desconectan después de un tiempo de inactividad y limitan las sesiones a 12 horas [22].

B. Dataset

Los datasets utilizados, son de la degradación de motores de turboventiladores que se encuentra bien detallado en [23] y [24], el mismo fue generado por C-MAPSS¹¹, la cual es una herramienta para la simulación de datos realistas de motores

comerciales de turboventiladores, está escrito en MATLAB y Simulink [25]. Su diagrama puede observarse en la figura 4.




Fig. 3. Diagrama simplificado del turboventilador simulado en C-MAPSS. Donde se muestran: a) *Fan*: Turbina, b) *Combustor*: Cámara de combustión, c) *N1*: Velocidad de la bobina del ventilador, d) *N2*: Velocidad de la bobina central, e) *LPT*: Turbina de baja presión, f) *HPT*: Turbina de alta presión, g) *HPC*: Compresor de alta presión, h) *LPC*: Compresor de baja presión, i) *Nozzle*: Inyector.

Los datasets consiste en múltiples series de tiempo multivariable. Cada uno se divide en subconjuntos de entrenamiento y prueba, al igual que cada serie de tiempo es de un motor diferente. Cada motor arranca con diferentes grados de desgaste inicial y variaciones de fabricación que el usuario desconoce. Este desgaste y variación se considera normal, y por ende no se lo considera como una condición de falla. Hay tres configuraciones operativas que tienen un efecto sustancial en el rendimiento del motor, las cuales también se incluyen en los datos. Cabe recalcar que los datos están contaminados con ruido del sensor [23].

El motor del turboventilador funciona normalmente al comienzo de cada serie de tiempo y este desarrolla una falla en algún momento durante todo el transcurso de la serie. En los datasets de entrenamiento, la magnitud de la falla crece hasta provocar deficiencia en el sistema. Por otra parte, en los datasets de prueba, la serie de tiempo finaliza antes de que exista alguna falla del sistema, y su objetivo es predecir el número de ciclos restantes antes de la falla en el dataset de prueba. De igual manera se tiene un vector de valores reales de vida útil restante (RUL¹²) para poder compararlos con los datos generados en el programa [23].

C. Memoria a Corto y Largo Plazo (LSTM)

Son un tipo de red neuronal recurrente (RNN) y estas tienen conexiones recurrentes entre estados ocultos, con un retraso de tiempo. Idealmente, las RNN son capaces de descubrir correlaciones temporales entre los eventos secuenciales que están muy lejos unos de otros. Sin embargo, en la práctica, es difícil entrenar RNN debido al Vanishing Gradient y los problemas de Exploding Gradient, explicados en [26] por Pascanu et al., por lo que las RNN se enfrentan a dificultades para manejar dependencias en secuencias de largo plazo. Por lo que, el modelo basado en RNN más efectivo se llaman LSTM.

TABLA I
DETALLE DE COLUMNAS DE LOS DATASETS DE PRUEBA Y ENTRENAMIENTO

Columna (s)	Descripción
1	Número de la unidad o motor.
2	Tiempo: Representado en ciclos.
3	Altitud.
4	Número mach.
5	Ángulo de resolución del acelerador
6	Temperatura total en el ventilador de entrada (°R)
7	Temperatura total el LPC de entrada (°R)
8	Temperatura total el HPC de salida (°R)
9	Temperatura total el LPC de salida (°R)
10	Presión del ventilador de entrada (psia)
11	Presión total en el ducto de By-pass (psia)
12	Presión total en la salida del HPC (psia)
13	Velocidad Física del ventilador (rpm)
14	Velocidad Física del núcleo (rpm)
15	Relación de presión del motor (P50 / P2)
16	Relación de presión del motor (P50 / P2)
17	Relación de flujo de combustible a Ps30 (pps/psi)
18	Velocidad del ventilador corregida (rpm)
19	Velocidad de núcleo conectada (rpm)
20	Relación de By-pass
21	Relación de quema de combustible con aire
22	Entalpía de sangrado
23	Velocidad exigida del ventilador (rpm)
24	Velocidad corregida exigida del ventilador (rpm)
25	Purga de refrigerante del HPT (lbm/s)
26	Purga de refrigerante del LPT (lbm/s)

⁶ Long Short Term Memory. - Memoria a Corto y Largo Plazo

⁷ Virtual Machine. - Máquina virtual.

⁸ Central Processing Unit. - Unidad Central de Procesamiento.

⁹ Graphical Processing Unit. - Unidad Gráfica de Procesamiento.

¹⁰ Tensor Processing Units. - Unidad de Procesamiento Tensorial.

¹¹ Commercial Modular Aero-Propulsion System Simulation. - Sistema de simulación de aéreo-propulsión modular comercial.

¹² Remaining Useful Life. - Vida Útil Restante.

Se introducen tres unidades de activación adicionales para controlar el flujo de información en la LSTM, lo cual es beneficioso para mantener información importante durante mucho tiempo. Formalmente, el LSTM puede formularse como:

$$i_t = \text{sigmoid}(W_i [x_t, h_t - 1] + b_i) \quad (1)$$

$$f_t = \text{sigmoid}(W_f [x_t, h_t - 1] + b_f) \quad (2)$$

$$o_t = \text{sigmoid}(W_o [x_t, h_t - 1] + b_o) \quad (3)$$

$$\tilde{c}_t = \tanh(W_c [x_t, h_t - 1] + b_c) \quad (4)$$

$$c_t = i_t \circ \tilde{c}_t + f_t \circ c_{t-1} \quad (5)$$

$$h_t = o_t \circ \tanh(c_t) \quad (6)$$

Donde W_x , son las matrices de pesos, b_x son los vectores de sesgo, y $x \in \{i, f, o, c\}$. A cada paso de tiempo t , x_t es un vector de entrada, c_t denota el vector de estado de memoria, y h_t es el vector de estado oculto, el cual es calculado en base a c_t . Las funciones de activación son sigmoides, siendo que sus valores son de 0 a 1, lo que permite o niega el flujo de información entre compuertas. Por lo tanto, los tres tipos de unidades de compuertas controlan la información que ingresa y sale de cada celda de memoria para cada paso de tiempo. La modulación de entrada \tilde{c}_t y la salida h_t , usualmente emplean a la tangente hiperbólica como función de activación. Debido a que el vector de estado interno \tilde{c}_t , debería poder aumentar o disminuir. La salida de \tanh puede ser positiva o negativa, lo que permite aumentos y disminuciones en el estado. Sin embargo, la salida sigmoidea es siempre positiva, por lo que los valores en el estado solo aumentarían. También, cabe recalcar que “ \circ ” denota la multiplicación por elementos. Debido a la arquitectura de compuerta, las LSTM son capaces de manejar las correlaciones temporales tanto a corto como a largo plazo en secuencias de tiempo.

De manera resumida, su estructura consiste en celdas de memoria como lo describe Felix A. Gers et al. en [27]. La cual su principal función es la de almacenar un valor y determinar el tiempo que debe almacenarse. Además, estas celdas seleccionan qué entradas se almacenan y también deciden si estas serán recordadas, eliminadas o si serán enviadas como salida de una red. Es uno de los modelos más utilizados cuando se trabaja con datos dependientes del tiempo [28], [29].




Fig. 4. Comparación entre una simple red neuronal recurrente (RNN) a la izquierda y una RNN con memoria a largo y corto plazo (LSTM) a la derecha.

D. Matriz de confusión

Generalmente se utilizan varias medidas de rendimiento para comparar y evaluar el poder de predicción de los modelos. Pero, en los problemas de clasificación, se utiliza el análisis de matriz de confusión. Este representa las clases predichas de datos de prueba de los modelos, para los cuales ya se conocen los valores reales. La Tabla 2 muestra la matriz de confusión para una clasificación binaria que presenta valores positivos y negativos como clases del modelo. Los verdaderos negativos (VN) son casos que pertenecen a una clase negativa y están correctamente clasificados como negativos por el modelo. Del mismo modo, los verdaderos positivos (VP) son el número de casos que pertenecen a la clase positiva y se clasifican correctamente como positivos. En contraste, los falsos positivos (FP) son muestras positivas que se clasifican incorrectamente como una clase negativa. Mientras que los falsos negativos (FN) son muestras de clase negativas clasificadas incorrectamente como positivas. Una matriz de confusión normalizada con clasificación perfecta tiene los valores de VP y VN de uno y FP y FN de cero [30].

TABLA II
MATRIZ DE CONFUSIÓN PARA EL PROBLEMA DE CLASIFICACIÓN BINARIA

	Clasificado Positivo	Clasificado Negativo
Positivo Actual	Verdaderos Positivos (VP)	Falsos Negativos (FN)
Negativo Actual	Falsos Positivos (FP)	Verdaderos Negativos (VN)

Con la matriz de confusión, se pueden calcular varias medidas de desempeño. Las métricas utilizadas en este estudio para fines de evaluación se explican a continuación:

- *Exactitud (Ex)*: Es una medida de predicciones correctas del modelo en comparación con los puntos de datos totales. Muestra con qué frecuencia el modelo clasifica las instancias correctamente. Se calcula como:

$$Ex = \frac{VP + VN}{VP + VN + FP + FN} \quad (7)$$

La exactitud es una buena medida donde los datos se equilibran para las etiquetas de cada clase. Sin embargo, en el caso de un conjunto de datos desequilibrados, la medida de exactitud sin otras medidas de rendimiento puede ser engañosa.

- *Tasa de clasificación errónea (T.C.E.)*: La tasa de clasificación errónea determina con qué frecuencia el modelo ha clasificado erróneamente una instancia en comparación con el total de instancias dadas. Se calcula como:

$$T.C.E. = \frac{FP + FN}{VP + VN + FP + FN} \quad (8)$$

Esta medida se usa principalmente para los problemas de clasificación binaria, ya que el cálculo de la tasa de clasificación errónea para problemas de clases múltiples es complicado.

- *F-Score*: Es una combinación de precisión (Pr) y sensibilidad (S). La precisión determina la exactitud del modelo. Es una relación de instancias positivas predichas correctamente al total

de instancias predichas positivamente. La precisión se representa como:

$$Pr = \frac{VP}{VP + FP} \quad (9)$$

Por el contrario, la sensibilidad proporciona una medida de la integridad del modelo. Es una relación de instancia positiva correctamente predicha a la instancia total de clase positiva en los datos de prueba. La sensibilidad se calcula como:

$$S = \frac{VP}{VP + FN} \quad (10)$$

La precisión representa el rendimiento del modelo con respecto a los falsos positivos, mientras que la sensibilidad representa el rendimiento, con respecto a los falsos negativos. Por ende, la F-Score transmite el equilibrio entre precisión y sensibilidad al tomar su media armónica ponderada. La F-Score se calcula de la siguiente manera:

$$F - Score = \frac{2 \cdot Pr \cdot S}{Pr + S} \quad (11)$$

E. Precisión del modelo de regresión

La evaluación de la precisión del modelo es una parte esencial del proceso en la creación de modelos de Machine Learning para describir qué tan bien se está desempeñando el modelo en sus predicciones. El modelo lineal puede ser un ejemplo típico de este tipo de problema, y la característica principal del problema de regresión es que los objetivos de un conjunto de datos contienen solo los números reales. Los errores representan que tantas equivocaciones está cometiendo el modelo en su predicción. El concepto básico de evaluación de precisión es comparar el objetivo original con el previsto según ciertas métricas. En el documento usaremos las siguientes:

- El MAE (error absoluto medio), que representa la diferencia entre los valores originales y predichos extraídos mediante la diferencia absoluta promedio sobre el conjunto de datos. Se obtiene mediante la siguiente formula:

$$MAE = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}| \quad (12)$$

- El R^2 (Coeficiente de determinación), representa el coeficiente de cuán bien se ajustan los valores en comparación con los valores originales. El valor de 0 a 1 interpretado como porcentajes. Cuanto mayor sea el valor, mejor será el modelo. Se representa con la siguiente formula:

$$R^2 = 1 - \frac{\sum (y_i - \hat{y})^2}{\sum (y_i - \bar{y})^2} \quad (13)$$

Donde \hat{y} es el valor predicho para para y . Y \bar{y} el valor de la media de y .

F. Optimizador Adam

Es un algoritmo para la optimización basada en el gradiente de primer orden de funciones estocásticas, el mismo está basado en estimaciones adaptativas de momentos de orden inferior. El método tiene las siguientes ventajas: es fácil de implementar, es




Fig. 6. Gráficos de la precisión (izquierda) y sensibilidad (derecha) del modelo, para el segundo dataset.




Fig. 7. Gráficos de la precisión (izquierda) y sensibilidad (derecha) del modelo, para el tercer dataset.




Fig. 8. Gráficos de la precisión (izquierda) y sensibilidad (derecha) del modelo, para el cuarto dataset.

computacionalmente eficiente, tiene pocos requisitos de memoria, es invariante para el cambio de escala diagonal de los gradientes y es muy adecuado para problemas que son grandes en términos de datos y/o parámetros. El método también es apropiado para objetivos no estacionarios y problemas con gradientes muy ruidosos y/o dispersos. Los hiperparámetros tienen interpretaciones intuitivas y generalmente requieren poca sintonización [31].

IV. RESULTADOS

Primero se predice si el motor fallará en algún período de tiempo o no, por lo tanto, nuestra etiqueta será 1 o 0, para definir si el turboventilador falla. Siendo este un problema de clasificación binaria. Para esta etiqueta binaria, pre-procesamos los datos y creamos una nueva etiqueta de RUL. Posteriormente, los datos se normalizan.

El modelo LSTM del presente documento tiene con dos capas LSTM y una capa completamente conectada. El modelo está entrenado para la clasificación binaria y, por lo tanto, trata de reducir la pérdida de entropía cruzada binaria. Luego, se utiliza el optimizador Adam para actualizar los parámetros del modelo. Los resultados del modelo entrenado pueden ser vistos




Fig. 5. Gráficos de la precisión (izquierda) y sensibilidad (derecha) del modelo, para el primer dataset.

en las figuras del 5 al 8. Y de manera numérica en la Tabla 3:

TABLA III
RESULTADOS DE LA CLASIFICACIÓN BINARIA

	Presición	Sensibilidad	VP	VN	FN	FP
Dataset 1	98.45%	92.12%	12486	2856	45	244
Dataset 2	95.78%	84.97%	32401	6768	298	1292
Dataset 3	99.32%	89.90%	16601	2787	19	313
Dataset 4	90.45%	92.29%	40328	7124	752	595

Posteriormente, comparamos los valores generados con nuestro predictor (función roja), con los datos reales de la simulación (función azul) de cada uno de los datasets. De esta manera podremos observar que tan eficiente fue nuestro modelo para la tarea. Véase las figuras del 9 al 12. Donde mientras menos se vea la función roja, significa que nuestra predicción se acercó a los datos reales. De igual manera, podemos observar los valores de precisión, sensibilidad y el F1-score, de las formulas 9, 10 y 11 respectivamente, en la tabla 4.

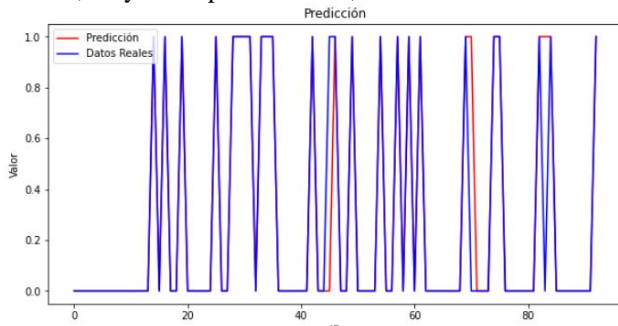


Fig. 9. Gráficos de comparación entre la predicción del modelo con respecto a los valores reales del primer dataset.

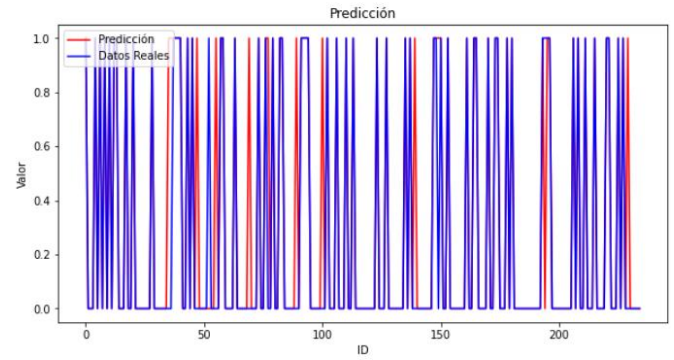


Fig. 10. Gráficos de comparación entre la predicción del modelo con respecto a los valores reales del segundo dataset.

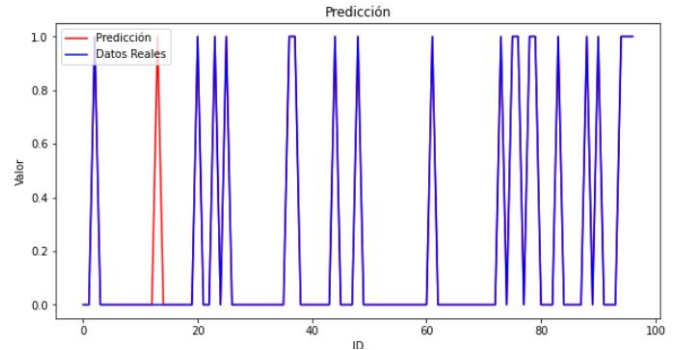


Fig. 11. Gráficos de comparación entre la predicción del modelo con respecto a los valores reales del tercer dataset.

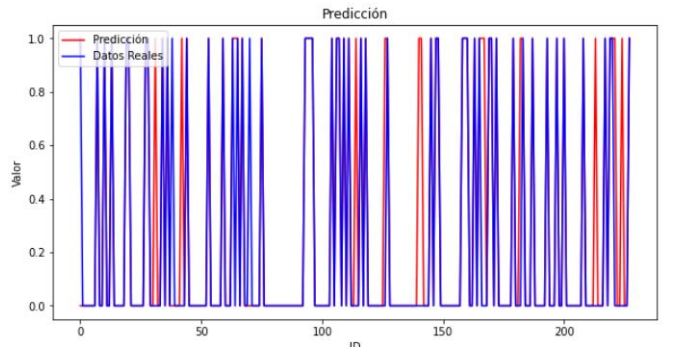


Fig. 12. Gráficos de comparación entre la predicción del modelo con respecto a los valores reales del cuarto dataset.

TABLA IV
COMPARACIÓN DE DATOS DE PREDICCIÓN DEL MODELO

	Presición	Sensibilidad	F1-score
Dataset 1	92.30%	96.00%	94.12%
Dataset 2	84.28%	96.72%	90.08%
Dataset 3	95.24%	100.00%	97.56%
Dataset 4	79.36%	94.34%	86.21%

Posteriormente, evaluamos la exactitud del modelo para cada uno de los datasets. Usando el MAE y el R^2 , de las formulas 12 y 13 respectivamente, para evaluar la eficiencia del modelo con respecto a la cantidad de ciclos restantes para cada uno de los turboventiladores. Véase las figuras 13 a 16.




Fig. 13. Gráficos de comparación entre la predicción del modelo con respecto a los valores reales del RUL de cada uno de los turboventiladores del primer dataset.




Fig. 14. Gráficos de comparación entre la predicción del modelo con respecto a los valores reales del RUL de cada uno de los turboventiladores del segundo dataset.




Fig. 15. Gráficos de comparación entre la predicción del modelo con respecto a los valores reales del RUL de cada uno de los turboventiladores del tercer dataset.




Fig. 16. Gráficos de comparación entre la predicción del modelo con respecto a los valores reales del RUL de cada uno de los turboventiladores del cuarto dataset.

Donde, el eje y trata sobre la cantidad de ciclos restantes antes de su falla de cada uno de los turboventiladores, mientras

que el eje x, trata sobre el ID de los ventiladores. En la Tabla 5 podemos ver los datos obtenidos.

TABLA V
COMPARACIÓN DE DATOS DE REGRESIÓN

	MAE	R ²
Dataset 1	11.85	0.84
Dataset 2	20.73	0.69
Dataset 3	23.43	0.64
Dataset 4	25.80	0.52

Los resultados en cuanto a regresión son aceptables, pero no óptimos, como cuando se hizo la clasificación binaria. Por lo que, es una gran oportunidad de mejora para trabajos futuros.

V. CONCLUSIONES

El mantenimiento predictivo es una nueva herramienta que tiene muchos avances tecnológicos en la actualidad, con un alto crecimiento en su demanda industrial a puertas de la cuarta revolución industrial. Este evita grandes costes económicos en cuanto a mantenimiento y producción se refiere, siendo una gran oferta y oportunidad para empresarios locales.

En el documento se presenta un modelo de RNN basada en LSTM para detectar la falla de un sistema de fabricación y predecir su condición de salud futura para el mantenimiento predictivo. En el modelo, se consideró la característica secuencial en el tiempo de los datos históricos de los sensores y configuraciones operacionales de los turboventiladores, con el fin de realizar una clasificación binaria para saber si fallaran antes de los 50 ciclos, lo que nos da una rápida idea de cuáles son los equipos para dar mantenimiento, dando tiempo suficiente al personal para organizar tiempos y conseguir repuestos. De igual manera, se realiza una regresión para conocer el resto de ciclos que tiene cada turboventilador, siendo una métrica más exacta para la gestión de mantenimiento en cualquier planta con maquinaria rotativa.


AGRADECIMIENTOS

Agradecer a mi madre, María del Pilar Alegría, y a mi padre, Mario Martínez. Por todo el apoyo que me dieron durante toda mi formación académica. A mis hermanas Yazzit y Mariet. A la Universidad Católica Boliviana “San Pablo” y al plantel docente del presente diplomado.

REFERENCIAS

- [1] Fundempres, “Estadísticas del Registro de Comercio de Bolivia - Enero de 2020,” 2020.
- [2] M. C. Camera, “Selection of diagnostic techniques and instrumentation in a predictive maintenance program. A case study,” *Decis. Support Syst.*, vol. 38, no. 4, pp. 539–555, Jan. 2005, doi: 10.1016/j.dss.2003.09.003.
- [3] J. Butler and C. Smalley, “An introduction to predictive maintenance,” *Pharm. Eng.*, vol. 37, no. 3, pp. 63–65, May 2017, doi: 10.1016/b978-0-7506-7531-4.x5000-3.
- [4] G. P. Sullivan, J. R. Pugh, A. P. Melendez, and W. D. Hunt, “Operations & Maintenance Best Practices A Guide to Achieving Operational Efficiency,” 2010.
- [5] “Practical Machinery Vibration Analysis and Predictive Maintenance - 1st Edition.” <https://www.elsevier.com/books/practical-machinery-vibration-analysis-and-predictive-maintenance/scheffer/978-0-7506-6275-8>

- (accessed Jun. 23, 2020).
- [6] A. Rivas, J. M. Fraile, P. Chamoso, A. González-Briones, I. Sittón, and J. M. Corchado, "A Predictive Maintenance Model Using Recurrent Neural Networks," in *Advances in Intelligent Systems and Computing*, 2020, vol. 950, pp. 261–270, doi: 10.1007/978-3-030-20055-8_25.
 - [7] A. G. Briones, P. Chamoso, A. Rivas, and S. Rodríguez, "Use of Gamification Techniques to Encourage Garbage Recycling. A Smart City Distributed predictive control based on multiagent systems View project ECOCASA-Intelligent Spaces And Social Computing For Behaviour Change In End-Consumers View project," 2018, doi: 10.1007/978-3-319-95204-8_56.
 - [8] A. González-Briones, A. Rivas, P. Chamoso, R. Casado-Vara, and J. M. Corchado, "Case-Based Reasoning and Agent Based Job Offer Recommender System," in *Advances in Intelligent Systems and Computing*, 2019, vol. 771, pp. 21–33, doi: 10.1007/978-3-319-94120-2_3.
 - [9] D. Bruneo and F. De Vita, "On the use of LSTM networks for predictive maintenance in smart industries," in *Proceedings - 2019 IEEE International Conference on Smart Computing, SMARTCOMP 2019*, 2019, pp. 241–248, doi: 10.1109/SMARTCOMP.2019.00059.
 - [10] S. Guldamlasioglu, O. Aydin, and D. Scientist, "Using LSTM networks to predict engine condition on large scale data processing framework," 2017, doi: 10.1109/ICEEE2.2017.7935834.
 - [11] L. Swanson, "Linking maintenance strategies to performance," *Int. J. Prod. Econ.*, vol. 70, no. 3, pp. 237–244, Apr. 2001, doi: 10.1016/S0925-5273(00)00067-0.
 - [12] F. Álvarez, A. Lora, J. Muñoz, and H. Quintián, "14th International Conference on Soft Computing Models in Industrial and Environmental Applications (SOCO 2019): Seville, Spain, May 13–15, 2019," 2019.
 - [13] K. R. Krishnanand, P. K. Dash, and M. H. Naeem, "Detection, classification, and location of faults in power transmission lines," *Int. J. Electr. Power Energy Syst.*, vol. 67, pp. 76–86, May 2015, doi: 10.1016/j.ijepes.2014.11.012.
 - [14] S. Abbas Taher and I. Sadeghkhani, "Estimation of magnitude and time duration of temporary overvoltages using ANN in transmission lines during power system restoration," *Elsevier*, doi: 10.1016/j.simpat.2010.01.016.
 - [15] R. J. Kuo and C. H. Li, "Predicting Remaining Useful Life of Ball Bearing Using an Independent Recurrent Neural Network," *MSIE 2020*, vol. 201, 2020, doi: 10.1145/3396743.3396765.
 - [16] O. Koca, O. T. Kaymakci, and M. Mercimek, *Advanced Predictive Maintenance with Machine Learning Failure Estimation in Industrial Packaging Robots*. 15th International Conference on DEVELOPMENT AND APPLICATION SYSTEMS.
 - [17] Ilesanmi Daniyana, "Artificial intelligence for predictive maintenance in the railcar learning factories," *Elsevier*, 2020, doi: 10.1016/j.promfg.2020.04.032.
 - [18] P. Do, A. Voisin, E. Levrat, and B. Iung, "A proactive condition-based maintenance strategy with both perfect and imperfect maintenance actions," *Reliab. Eng. Syst. Saf.*, vol. 133, pp. 22–32, 2015, doi: 10.1016/j.ress.2014.08.011.
 - [19] D. Zhou, H. Zhang, and S. Weng, "A novel prognostic model of performance degradation trend for power machinery maintenance," *Energy*, vol. 78, pp. 740–746, Dec. 2014, doi: 10.1016/j.energy.2014.10.067.
 - [20] X. Liu, Q. Xu, and N. Wang, "A survey on deep neural network-based image captioning," *Vis. Comput.*, vol. 35, no. 3, pp. 445–470, Mar. 2019, doi: 10.1007/s00371-018-1566-y.
 - [21] Q. Wang, S. Bu, and Z. He, "Achieving Predictive and Proactive Maintenance for High-Speed Railway Power Equipment with LSTM-RNN," *IEEE Trans. Ind. Informatics*, pp. 1–1, Jan. 2020, doi: 10.1109/tii.2020.2966033.
 - [22] M. J. Nelson and A. K. Hoover, "Notes on Using Google Co-laboratory in AI Education," 2020, doi: 10.1145/3341525.3393997.
 - [23] A. Saxena, K. Goebel, D. Simon, and N. Eklund, "Damage propagation modeling for aircraft engine run-to-failure simulation," in *2008 International Conference on Prognostics and Health Management, PHM 2008*, 2008, doi: 10.1109/PHM.2008.4711414.
 - [24] D. K. Frederick, J. A. Decastro, and J. S. Litt, "User's Guide for the Commercial Modular Aero-Propulsion System Simulation (C-MAPSS)," 2007. Accessed: 25-Jun-2020. [Online]. Available: <http://www.sti.nasa.gov>.
 - [25] E. Ramasso, A. Saxena, and A. Performance Benchmarking, "Performance Benchmarking and Analysis of Prognostic Methods for CMAPSS Datasets. Performance Benchmarking and Analysis of Prognostic Methods for CMAPSS Datasets," 2014. Accessed: 25-Jun-2020. [Online]. Available: <https://hal.archives-ouvertes.fr/hal-01324587>.
 - [26] R. Pascanu, T. Mikolov, and Y. Bengio, "On the difficulty of training recurrent neural networks," 2013.
 - [27] F. A. Gers, N. N. Schraudolph, and J. Schmidhuber, "Learning Precise Timing with LSTM Recurrent Networks," 2002. Accessed: 25-Jun-2020. [Online]. Available: www.idsia.ch.
 - [28] F. A. Gers, D. Eck, and J. Schmidhuber, "Applying LSTM to Time Series Predictable Through Time-Window Approaches," Springer, London, 2002, pp. 193–200.
 - [29] Z. C. Lipton, D. C. Kale, C. Elkan, R. P. Wetzel Laura, and L. K. Whittier Virtual PICU, "LEARNING TO DIAGNOSE WITH LSTM RECURRENT NEURAL NETWORKS." Accessed: 25-Jun-2020. [Online]. Available: <http://zacklipton.com>.
 - [30] Z. Allah Bukhsh, A. Saeed, I. Stipanovic, and A. G. Doree, "Predictive maintenance using tree-based classification techniques: A case of railway switches," *Transp. Res. Part C Emerg. Technol.*, vol. 101, pp. 35–54, Apr. 2019, doi: 10.1016/j.trc.2019.02.001.
 - [31] D. P. Kingma and J. Lei Ba, "ADAM: A METHOD FOR STOCHASTIC OPTIMIZATION."



Albert Martínez Alegría, nacido en La Paz, Bolivia. Graduado de Ingeniería Mecatrónica en la Universidad Católica Boliviana "San Pablo", La Paz, el 2018. Actualmente, cursando una maestría en Sistemas Mecatrónicos, con diplomado en Robótica en la misma universidad. Con experiencia laboral industrial en Ingeniería y Mantenimiento, de la Cervecería Boliviana Nacional S.A. el 2018. Y actualmente, como representante comercial de equipos médicos de las marcas Topcon, Huvitz, entre otros; con Premier Internacional.